

从熵正则强化学习到张量网络表示的受控格点随机过程

Contents

1	问题的重新定位	2
1.1	原始maze 问题的问题在哪里	2
1.2	固定格点随机模型还不够	2
2	受控格点MDP 的基本形式	3
2.1	many-body 状态空间	3
2.2	动作必须是物理控制变量	3
2.3	state-action Perron 问题	4
3	具体模型：最近邻reward 的多agent 受控链	4
3.1	状态空间与hard-core 约束	4
3.2	action: 选择一个局域移动	5
3.3	最近邻reward	5
3.4	state-action tilted operator	6
4	这个模型的MPS/MPO 表示	7
4.1	把state-action 对编码成一维局域变量	7
4.2	MPS 诱导的policy	7
4.3	局域transition gate 的MPO 结构	8
4.4	最近邻reward 的diagonal MPO	8
4.5	next-action prior 的MPO	9
4.6	完整state-action tilted MPO	9
5	u-θ learning 的位置	10
5.1	它不是替代RL 的物理动机, 而是model-free 求解器	10
5.2	用MPS 参数做随机优化	10
6	热力学极限中应测量什么	11
6.1	自由能密度	11
6.2	policy 诱导的稳态与局域观测量	11
6.3	有限尺寸标度与iMPS	12
7	与已有工作的关系	12
7.1	与KCM 大偏差MPS 工作的关系	12
7.2	与tensor-network RL 工作的关系	12

8 建议的研究路线	12
8.1 第一步: 小体系精确验证	12
8.2 第二步: MPO-MPS model-based 求解	13
8.3 第三步: MPS u - θ learning	13
8.4 第四步: 有限尺寸标度与热力学极限	13
9 小体系三步验证结果	13
9.1 验证设置	13
9.2 第一步: 精确state-action Perron 解	13
9.3 第二步: MPO-MPS model-based 求解	14
9.4 第三步: MPS u - θ learning	15
10 总结	15

1 问题的重新定位

1.1 原始maze 问题的问题在哪里

Arriojas 等人的文章给出了一条很有用的数学线索: 熵正则强化学习的长时间极限可以写成tilted Markov operator 的Perron 本征问题。对有限状态动作空间, 设

$$z = (s, a), \quad P_0(z' | z) = p(s' | s, a) \pi_0(a' | s'), \quad (1)$$

其中 π_0 是prior policy。一步reward 为 $r(z)$ 。对应的tilted operator 为

$$K_\beta(z' | z) = e^{\beta r(z)} P_0(z' | z). \quad (2)$$

长时间轨迹权重由 K_β 的主本征结构控制:

$$K_\beta u_\beta = \rho_\beta u_\beta, \quad \ell_\beta^\top K_\beta = \rho_\beta \ell_\beta^\top. \quad (3)$$

在这个记号下, 最优policy 为

$$\pi_\beta^*(a | s) = \frac{\pi_0(a | s) u_\beta(s, a)}{\sum_b \pi_0(b | s) u_\beta(s, b)}. \quad (4)$$

有限maze 的例子适合说明这一点, 但它不适合成为热力学极限问题。原因是单个agent 在 $L \times L$ maze 中运动时, 状态空间虽然随 L 增大, 但它并不是一个由大量局域自由度组成的many-body 配置空间。把maze 做大更多是在做单粒子的无限体积极限, 而不是统计物理意义上的自由度趋于无穷。

因此, 如果目标是把这套理论和张量网络、热力学极限联系起来, 不能只把maze 放大。我们需要把MDP 本身改造成一系列受控many-body 随机过程。

1.2 固定格点随机模型还不够

一个自然想法是从East model、FA model、SSEP、ASEP 等一维格点随机模型出发。这些模型确实有清楚的热力学极限, 也天然可以用MPO/MPS 处理tilted generator。但如果只研究一个固定的Markov process

$$x_t \rightarrow x_{t+1}, \quad (5)$$

那么action 变量消失了。此时我们研究的是被偏置的轨迹系综或Doob transform, 而不是一个真正的强化学习问题。

固定动力学的tilted operator 是

$$\tilde{P}_\lambda(x' | x) = P(x' | x)e^{\lambda A(x, x')}, \quad (6)$$

主本征值给出scaled cumulant generating function。这是非平衡统计物理中的dynamical large deviation 问题。它与Arriojas 文章有同构的谱结构，但 u - θ learning 只是求主本征向量的一种样本算法，并没有真正体现agent 的决策。

所以本文要走的路线是：

受控格点随机模型 = many-body Markov process + agent action + entropy regularization.

 (7)

2 受控格点MDP 的基本形式

2.1 many-body 状态空间

考虑一维长度为 L 的链。每个site 有局域变量

$$x_i \in \mathcal{X}, \quad |\mathcal{X}| = d. \quad (8)$$

全局状态为

$$x = (x_1, \dots, x_L) \in \mathcal{X}^L. \quad (9)$$

例如：

$$x_i = n_i \in \{0, 1\} \quad \text{表示occupation variable}, \quad (10)$$

或者

$$x_i = \sigma_i \in \{-1, +1\} \quad \text{表示Ising spin}. \quad (11)$$

热力学极限不是 $T \rightarrow \infty$ ，而是

$$L \rightarrow \infty. \quad (12)$$

长时间极限仍然存在，用来提取轨迹自由能；热力学极限则要求研究

$$\lim_{L \rightarrow \infty} \frac{1}{L} \log \rho_{\beta, L} \quad (13)$$

这样的密度量。

2.2 动作必须是物理控制变量

为了让问题保持RL 的含义，action 不能只是事后给transition 贴标签，而必须是agent 能选择的控制。几种合适的action 设计包括：

1. 选择一个site i 尝试更新；
2. 选择一个bond $(i, i + 1)$ 尝试hopping；
3. 选择局域field、chemical potential 或hopping bias；
4. 选择局域温度、翻转速率或驱动强度；
5. 在量子版本中选择局域gate、measurement setting 或feedback operation。

于是MDP 的基本对象是

$$p(x' | x, a), \quad r(x, a), \quad \pi(a | x). \quad (14)$$

prior policy 记为 $\pi_0(a | x)$ ，它可以是均匀选择site、均匀选择bond，或某个无控制的自然采样规则。

2.3 state-action Perron 问题

定义state-action 变量

$$z = (x, a). \quad (15)$$

在prior policy 下, 一步state-action 转移核为

$$P_0(x', a' | x, a) = p(x' | x, a)\pi_0(a' | x'). \quad (16)$$

tilted operator 为

$$K_\beta(x', a' | x, a) = e^{\beta r(x, a)} p(x' | x, a)\pi_0(a' | x'). \quad (17)$$

长时间极限下, 核心方程是

$$\sum_{x', a'} K_\beta(x', a' | x, a) u_\beta(x', a') = \rho_\beta u_\beta(x, a). \quad (18)$$

等价地,

$$e^{\beta r(x, a)} \mathbb{E}_{x' \sim p(\cdot | x, a), a' \sim \pi_0(\cdot | x')} [u_\beta(x', a')] = \rho_\beta u_\beta(x, a). \quad (19)$$

最优policy 仍由Perron eigenfunction 给出:

$$\pi_\beta^*(a | x) = \frac{\pi_0(a | x) u_\beta(x, a)}{\sum_b \pi_0(b | x) u_\beta(x, b)}. \quad (20)$$

这一步是RL 与普通大偏差谱问题的分界线。普通大偏差只需要tilted generator 的主本征值和Doob transform; 这里还要从 $u_\beta(x, a)$ 读出一个可执行的最优决策规则。

3 具体模型: 最近邻reward 的多agent 受控链

3.1 状态空间与hard-core 约束

现在把原来的单agent maze 改成一个真正的many-body MDP。考虑长度为 L 的一维链, 每个格点最多容纳一个agent。用occupation variable 表示状态:

$$n_i \in \{0, 1\}, \quad n = (n_1, \dots, n_L) \in \{0, 1\}^L. \quad (21)$$

其中 $n_i = 1$ 表示第 i 个格点被某个agent 占据, $n_i = 0$ 表示空位。若希望固定agent 数, 则限制在

$$\mathcal{S}_{L, N} = \left\{ n \in \{0, 1\}^L : \sum_{i=1}^L n_i = N \right\}. \quad (22)$$

热力学极限取

$$L \rightarrow \infty, \quad N \rightarrow \infty, \quad \bar{\rho} = \frac{N}{L} \text{ fixed}. \quad (23)$$

这与单agent maze 的区别是本质性的: 状态不再是一个位置变量, 而是一条长度为 L 的二值构型。状态空间维数随 L 指数增长, 或在固定粒子数sector 中按 $\binom{L}{N}$ 增长。

3.2 action: 选择一个局域移动

动作定义为选择一条相邻bond 和一个移动方向:

$$a = (i, \sigma), \quad i = 1, \dots, L-1, \quad \sigma \in \{+, -\}. \quad (24)$$

其中 $\sigma = +$ 表示尝试把agent 从 i 移到 $i+1$, $\sigma = -$ 表示尝试把agent 从 $i+1$ 移到 i 。这就是“action 是移动它们”的精确定义。

给定action $a = (i, +)$, 只有当局域构型为

$$(n_i, n_{i+1}) = (1, 0) \quad (25)$$

时, 向右移动才合法; 移动后局域构型变为 $(0, 1)$ 。若局域构型不是 $(1, 0)$, 则状态保持不变。类似地, 给定 $a = (i, -)$, 只有当

$$(n_i, n_{i+1}) = (0, 1) \quad (26)$$

时, 向左移动才合法; 移动后局域构型变为 $(1, 0)$ 。

为了允许环境随机性, 可以引入成功概率 $q_\sigma \in [0, 1]$ 。定义局域两格点transition gate

$$G_i^\sigma(n'_i, n'_{i+1} | n_i, n_{i+1}). \quad (27)$$

对 $\sigma = +$,

$$G_i^+(01 | 10) = q_+, \quad G_i^+(10 | 10) = 1 - q_+, \quad (28)$$

其它不满足右移条件的构型保持不变:

$$G_i^+(ab | ab) = 1, \quad ab \neq 10. \quad (29)$$

对 $\sigma = -$,

$$G_i^-(10 | 01) = q_-, \quad G_i^-(01 | 01) = 1 - q_-, \quad (30)$$

其它不满足左移条件的构型保持不变:

$$G_i^-(ab | ab) = 1, \quad ab \neq 01. \quad (31)$$

于是全局transition kernel 为

$$p(n' | n, a = (i, \sigma)) = G_i^\sigma(n'_i, n'_{i+1} | n_i, n_{i+1}) \prod_{k \neq i, i+1} \delta_{n'_k, n_k}. \quad (32)$$

确定性移动是 $q_+ = q_- = 1$ 的特例。

3.3 最近邻reward

现在把reward 取成移动后构型的最近邻函数。最基本的选择是

$$\Phi(n') = -V \sum_{k=1}^{L-1} n'_k n'_{k+1}. \quad (33)$$

若 $V > 0$, 相邻占据受到惩罚, agent 倾向分散; 若 $V < 0$, 相邻占据受到奖励, agent 倾向聚集。这正是“reward 依赖最近邻agent 位置”的occupation 版本。

也可以加入方向性输运项。定义一步电流

$$J(n, a, n') = \begin{cases} +1, & a = (i, +) \text{ 且 } 10 \rightarrow 01 \text{ 成功发生,} \\ -1, & a = (i, -) \text{ 且 } 01 \rightarrow 10 \text{ 成功发生,} \\ 0, & \text{否则.} \end{cases} \quad (34)$$

完整一步reward 取为

$$r(n, a, n') = \Phi(n') + \lambda J(n, a, n') - c_\sigma. \quad (35)$$

其中 λ 控制是否鼓励净向右输运, c_σ 是动作代价。若只想研究最近邻相互作用, 可令 $\lambda = 0$ 。

在熵正则control-as-inference 中, 长时间轨迹权重包含

$$\exp \left[\beta \sum_{t=0}^{T-1} r(n_t, a_t, n_{t+1}) \right]. \quad (36)$$

因为 $\Phi(n')$ 是最近邻加和, 指数权重可分解为相邻bond 权重:

$$e^{\beta \Phi(n')} = \prod_{k=1}^{L-1} \omega(n'_k, n'_{k+1}), \quad \omega(a, b) = e^{-\beta V ab}. \quad (37)$$

这正是MPO 表示成立的关键局域性。

3.4 state-action tilted operator

令prior policy 为均匀选择bond 和方向:

$$\pi_0(a | n) = \frac{1}{2(L-1)}. \quad (38)$$

也可以把非法动作排除在prior 之外, 但均匀选择所有动作更简单, 因为非法动作已经通过(32) 自动变成“不动” transition。

state-action tilted operator 为

$$K_\beta(n', a' | n, a) = p(n' | n, a) \pi_0(a' | n') e^{\beta r(n, a, n')}. \quad (39)$$

Perron 方程为

$$\sum_{n', a'} p(n' | n, a) \pi_0(a' | n') e^{\beta r(n, a, n')} u_\beta(n', a') = \rho_{\beta, L} u_\beta(n, a). \quad (40)$$

由此得到最优移动策略

$$\pi_\beta^*(a | n) = \frac{\pi_0(a | n) u_\beta(n, a)}{\sum_b \pi_0(b | n) u_\beta(n, b)}. \quad (41)$$

因此agent 学到的是: 在当前多agent 构型 n 下, 选择哪条bond、哪个方向移动, 才能在最近邻相互作用、电流偏置和熵正则代价之间达到最优折中。

4 这个模型的MPS/MPO 表示

4.1 把state-action 对编码成一维局域变量

Perron eigenfunction 的自变量不是单纯的occupation 构型 n ，而是state-action 对

$$(n, a) = (n, (i, \sigma)). \quad (42)$$

为了用MPS 表示 $u_\beta(n, a)$ ，把action 写成一条bond-marker 字符串。对每条bond $(i, i + 1)$ 定义

$$m_i \in \{0, +, -\}, \quad i = 1, \dots, L - 1. \quad (43)$$

若action 是 $a = (i, +)$ ，则 $m_i = +$ ，其余 $m_j = 0$ ；若action 是 $a = (i, -)$ ，则 $m_i = -$ ，其余 $m_j = 0$ 。合法action-marker sector 为

$$\mathcal{M}_L = \left\{ m \in \{0, +, -\}^{L-1} : \sum_{i=1}^{L-1} \mathbf{1}_{m_i \neq 0} = 1 \right\}. \quad (44)$$

为方便写成长度为 L 的MPS，可令 $m_L = 0$ ，并把第 i 个site 的局域物理指标取为

$$y_i = (n_i, m_i), \quad y_i \in \{0, 1\} \times \{0, +, -\} \quad (i < L), \quad (45)$$

最后一个site 固定 $m_L = 0$ 。因此bulk 局域维数是

$$d_{\text{loc}} = 2 \times 3 = 6. \quad (46)$$

在这个扩展空间中，state-action Perron eigenfunction 写成MPS:

$$u_\theta(n, m) = \sum_{\alpha_1, \dots, \alpha_{L-1}} A_{y_1, \alpha_1}^{[1]} A_{\alpha_1, y_2, \alpha_2}^{[2]} \cdots A_{\alpha_{L-1}, y_L}^{[L]}. \quad (47)$$

这里 m 与 a 一一对应，所以也写作 $u_\theta(n, a)$ 。实际计算时只在(44) 的合法sector 上评估 u_θ 。

Perron eigenfunction 应为正。可以采取两种方式:

1. 直接优化 u_θ ，并通过非负张量或投影保持正性；
2. 写成

$$u_\theta(n, a) = \exp f_\theta(n, a), \quad (48)$$

其中 f_θ 由MPS 或tensor train 表示。

第一种更贴近线性本征值问题；第二种数值上更稳定，尤其适合sample-based learning。

4.2 MPS 诱导的policy

给定 $u_\theta(n, a)$ ，policy 由control-as-inference 公式确定，而不是任意另设一个actor:

$$\pi_\theta(a | n) = \frac{\pi_0(a | n) u_\theta(n, a)}{\sum_b \pi_0(b | n) u_\theta(n, b)}. \quad (49)$$

在当前模型中action 数为 $2(L - 1)$ ，所以分母可写成显式有限和:

$$Z_\theta(n) = \sum_{i=1}^{L-1} \sum_{\sigma=\pm} \pi_0((i, \sigma) | n) u_\theta(n, (i, \sigma)). \quad (50)$$

若 π_0 是(38) 的均匀prior, 则

$$\pi_\theta((i, \sigma) | n) = \frac{u_\theta(n, (i, \sigma))}{\sum_{j=1}^{L-1} \sum_{\tau=\pm} u_\theta(n, (j, \tau))}. \quad (51)$$

因此MPS 的实际用途非常明确: 它给每一个候选局域移动 (i, σ) 一个正权重, 再归一化为移动概率。

4.3 局域transition gate 的MPO 结构

先只看由action 决定的controlled transition。对固定 $a = (i, \sigma)$, (32) 只作用在两个相邻site 上。因此它是一个局域gate:

$$T_{i,\sigma} = I_1 \otimes \cdots \otimes I_{i-1} \otimes G_i^\sigma \otimes I_{i+2} \otimes \cdots \otimes I_L. \quad (52)$$

若把action marker 也作为物理指标的一部分, 输入marker $m_i = \sigma$ 用来选择这个gate。定义projector

$$\mathcal{P}_{i,\sigma}^{\text{in}}(m) = \mathbf{1}_{m_i=\sigma} \prod_{j \neq i} \mathbf{1}_{m_j=0}. \quad (53)$$

则“读取输入action 并执行对应局域移动” 的operator 可写成

$$\mathcal{T} = \sum_{i=1}^{L-1} \sum_{\sigma=\pm} \mathcal{P}_{i,\sigma}^{\text{in}} T_{i,\sigma}. \quad (54)$$

这是一个MPO。理由是 $\mathcal{T}$ 是沿链的有限状态自动机: 它从左到右扫描marker, 在没有看到非零marker 前传播“idle” 状态; 看到唯一的+ 或- marker 时, 在当前bond 上放置 G_i^+ 或 G_i^- ; 之后传播“done” 状态并要求不再出现第二个marker。这种“局域项之和加单marker 约束” 的结构需要的MPO bond dimension 不随 L 增长。

4.4 最近邻reward 的diagonal MPO

最近邻reward 的指数权重是

$$e^{\beta\Phi(n')} = \prod_{k=1}^{L-1} \omega(n'_k, n'_{k+1}), \quad \omega(a, b) = e^{-\beta V a b}. \quad (55)$$

它定义了一个只依赖输出构型 n' 的diagonal operator:

$$\mathcal{D}_\Phi(n' | n') = e^{\beta\Phi(n')}. \quad (56)$$

这个operator 是MPO, 因为它是一个一维最近邻classical Boltzmann weight。显式地, 可把 ω 分解为有限秩形式

$$\omega(a, b) = \sum_{\mu=1}^r B_{a\mu} C_{\mu b}, \quad r \leq 2. \quad (57)$$

于是

$$e^{\beta\Phi(n')} = \sum_{\mu_1, \dots, \mu_{L-1}} B_{n'_1 \mu_1} C_{\mu_1 n'_2} B_{n'_2 \mu_2} \cdots C_{\mu_{L-1} n'_L}. \quad (58)$$

这就是diagonal MPO 的矩阵乘积形式。若还加入局域势能 $\sum_i U_i n'_i$, 只需把单点权重吸收到相邻张量中。

电流项和动作代价是action-local 的。对marker $m_i = \sigma$, 定义

$$e^{\beta[\lambda J(n,a,n')-c_\sigma]}. \quad (59)$$

它只依赖active bond 的输入/输出局域构型与方向marker, 因此可并入 G_i^σ :

$$\hat{G}_i^\sigma = e^{\beta[\lambda J_i^\sigma - c_\sigma]} G_i^\sigma. \quad (60)$$

因此最近邻interaction 给出diagonal MPO, 移动电流和动作代价给出active bond 上的tilted local gate。

4.5 next-action prior 的MPO

state-action operator 不只从 n 到 n' , 还要从当前action marker m 到下一步action marker m' 。这一步由prior policy 给出。均匀prior 时,

$$\Pi_0(m' | n') = \frac{1}{2(L-1)} \mathbf{1}_{m' \in \mathcal{M}_L}. \quad (61)$$

它不依赖 n' , 只要求输出marker 字符串合法且只有一个非零marker。这个约束同样是有限状态自动机, 因此也是MPO: 从左到右扫描输出marker, 记录是否已经看到一个非零marker, 并在链末端只接受“恰好看到一次” 的路径。

在实际算法中, 不一定要显式构造 Π_0 。Perron 方程右边需要的是

$$\sum_{a'} \pi_0(a' | n') u_\theta(n', a') = \frac{1}{2(L-1)} \sum_{j=1}^{L-1} \sum_{\tau=\pm} u_\theta(n', (j, \tau)). \quad (62)$$

这个量可以通过枚举 $2(L-1)$ 个marker 位置直接收缩MPS 得到, 复杂度多一个 $O(L)$ 因子。若要做完全model-based 的MPO-MPS 本征值求解, 则把 Π_0 显式并入MPO。

4.6 完整state-action tilted MPO

把上述三个部分合在一起, 完整tilted operator 可形式化写为

$$K_\beta = \Pi_0 \mathcal{D}_\Phi \hat{\mathcal{T}}, \quad (63)$$

其中

$$\hat{\mathcal{T}} = \sum_{i=1}^{L-1} \sum_{\sigma=\pm} \mathcal{P}_{i,\sigma}^{\text{in}} \hat{T}_{i,\sigma}, \quad \hat{T}_{i,\sigma} = I \otimes \cdots \otimes \hat{G}_i^\sigma \otimes \cdots \otimes I. \quad (64)$$

这里 $\hat{\mathcal{T}}$ 执行由当前action 指定的局域移动并加入active-bond reward; $\mathcal{D}_\Phi$ 加入移动后构型的最近邻相互作用reward; Π_0 生成下一步prior action。每一项都是MPO, 有限个MPO 的乘积仍是MPO。因此

$$K_\beta(n', m' | n, m) = \sum_{\gamma_1, \dots, \gamma_{L-1}} W_{\gamma_0, \gamma_1}^{[1]}(y'_1, y_1) W_{\gamma_1, \gamma_2}^{[2]}(y'_2, y_2) \cdots W_{\gamma_{L-1}, \gamma_L}^{[L]}(y'_L, y_L), \quad (65)$$

其中 $y_i = (n_i, m_i)$ 、 $y'_i = (n'_i, m'_i)$, 边界bond index 固定为 $\gamma_0 = \gamma_L = 1$ 。MPO bond index γ_i 的物理含义是有限状态自动机的内部状态: 它需要记录输入marker 是否已经被发现、局域gate 是否正在跨越当前bond、输出marker 是否已经被生成, 以及最近邻reward 的一个短程记忆指标。

于是model-based 问题就是非厄米MPO 的主本征问题:

$$K_\beta^{\text{MPO}} u_\theta^{\text{MPS}} \approx \rho_{\beta,L} u_\theta^{\text{MPS}}. \quad (66)$$

可用DMRG-like sweeping、Arnoldi-DMRG 或VUMPS-like fixed point 方法求解。它的功能是提供基准答案:

1. 检查MPS 是否能表达 $u_\beta(n, a)$;
2. 计算 $\rho_{\beta, L}$ 和自由能密度;
3. 通过(49) 生成最优移动policy;
4. 与sample-based u - θ learning 比较。

5 u - θ learning 的位置

5.1 它不是替代RL 的物理动机, 而是model-free 求解器

在受控格点MDP 中, u - θ learning 的合理定位是:

不知道完整 $p(n' | n, a)$ 时, 用采样transition 学Perron eigenfunction。 (67)

它学习的不是普通discounted value function, 而是方程

$$e^{\beta r(n, a, n')} u_\theta(n', a') \approx \rho u_\theta(n, a) \quad (68)$$

所定义的multiplicative Bellman eigenfunction。

从prior dynamics 采样

$$a_t \sim \pi_0(\cdot | n_t), \quad n_{t+1} \sim p(\cdot | n_t, a_t), \quad a_{t+1} \sim \pi_0(\cdot | n_{t+1}). \quad (69)$$

定义单样本残差

$$\delta_t = e^{\beta r_t} u_\theta(n_{t+1}, a_{t+1}) - \rho u_\theta(n_t, a_t). \quad (70)$$

样本损失为

$$\mathcal{L}(\theta, \rho) = \mathbb{E}_{\pi_0, p} [\delta_t^2]. \quad (71)$$

这就是tabular u - θ learning 的张量网络版本。

5.2 用MPS 参数做随机优化

若

$$u_\theta(n, a) = \exp f_\theta(n, a), \quad (72)$$

则可以用log-residual 避免数值爆炸:

$$\varepsilon_t = \beta r_t + f_\theta(n_{t+1}, a_{t+1}) - f_\theta(n_t, a_t) - \log \rho. \quad (73)$$

理想情况下 $\varepsilon_t = 0$ 。于是可最小化

$$\mathcal{L}_{\log}(\theta, \rho) = \mathbb{E}_{\pi_0, p} [\varepsilon_t^2]. \quad (74)$$

这个写法牺牲了一些原始线性Perron 方程的结构, 但更适合大体系数值优化。实际算法可以是:

1. 初始化MPS 或iMPS 参数 $f_\theta(n, a)$;
2. 用prior policy 与原始环境采样 $(n_t, a_t, r_t, n_{t+1}, a_{t+1})$;
3. 计算 ε_t ;

4. 用自动微分或MPS 局域环境更新 θ ;
5. 同时更新 $\log \rho$;
6. 周期性canonicalize MPS, 并控制bond dimension;
7. 用(49) 生成policy, 模拟受控轨迹并测量observables。

这一路线保留了RL 的含义: agent 通过采样交互学习一个能够诱导最优控制策略的state-action eigenfunction, 而不是预先构造完整的指数大矩阵。

6 热力学极限中应测量什么

6.1 自由能密度

有限长度 L 下, 主本征值为 $\rho_{\beta,L}$ 。离散时间中自然定义

$$\psi_L(\beta) = \log \rho_{\beta,L}. \quad (75)$$

若reward 是extensive 的局域加和, 热力学极限中稳定对象通常是

$$\psi(\beta) = \lim_{L \rightarrow \infty} \frac{1}{L} \psi_L(\beta). \quad (76)$$

若采用Arriojas 的记号 $\rho = e^{-\beta\theta}$, 则对应

$$\theta_L = -\frac{1}{\beta} \log \rho_{\beta,L}, \quad \theta_\infty = \lim_{L \rightarrow \infty} \frac{\theta_L}{L}. \quad (77)$$

6.2 policy 诱导的稳态与局域观测量

给定 $\pi_\theta(a | n)$, 可以模拟受控动力学

$$n_t \xrightarrow{a_t \sim \pi_\theta(\cdot | n_t)} n_{t+1}. \quad (78)$$

应测量的量包括:

1. 电流密度 J/L ;
2. activity density;
3. density profile $\langle n_i \rangle$;
4. 最近邻占据密度 $\langle n_i n_{i+1} \rangle$;
5. 两点关联函数和相关长度;
6. entropy/control cost;
7. 与model-based Doob dynamics 的KL divergence。

这些量比单纯的episode return 更接近统计物理问题的核心。

6.3 有限尺寸标度与iMPS

第一阶段可以做有限 L :

$$L = 8, 12, 16, 24, \dots \quad (79)$$

并观察

$$\frac{1}{L} \log \rho_{\beta, L}, \quad \langle J \rangle / L, \quad \xi_L \quad (80)$$

的收敛。

第二阶段才考虑iMPS/iMPO。若模型在bulk 平移不变，则用一个或两个site 的unit cell 表示无限链固定点。此时研究对象不再是完整向量 $u(x, a)$ ，而是bulk tensor fixed point 与局域环境。

7 与已有工作的关系

7.1 与KCM 大偏差MPS 工作的关系

East model、FA model 等kinetically constrained models 的动力学大偏差已经被MPS/MPO 方法研究过。那些工作通常从固定Markov generator $\mathcal{L}$ 出发，构造tilted generator $\mathcal{L}_s$ ，再用MPS 求最大实部本征值：

$$\mathcal{L}_s r_s = \theta(s) r_s. \quad (81)$$

这给了我们一个重要参照：tilted stochastic operator 的主本征态确实可以有低bond dimension 表示。

但本文路线与其不同：我们不只研究固定动力学的rare trajectory ensemble，而是引入action，并从state-action eigenfunction 构造policy。

最近Cea、Cech、Carollo、Lesanovsky 和Banuls 的monitored quantum systems 工作“Large deviations and conditioned monitored quantum systems: a tensor network approach”也采用了同一类思想：不枚举整条轨迹，而是把带有counting-field 或conditioning 参数的离散时间trajectory transfer matrix 表示为tensor network，再通过反复作用transfer operator 和压缩MPS 来得到长时间大偏差性质与conditioned many-body state。本文的小体系实现借鉴的是这个结构层面的思想：先把tilted trajectory ensemble 的一步转移写成MPO，再把Perron eigenfunction 写成MPS。

7.2 与tensor-network RL 工作的关系

已有tensor-network RL 工作通常直接用MPS 表示policy 或value function，例如

$$V_\theta(x), \quad \pi_\theta(a | x). \quad (82)$$

本文的不同点是：policy 不是任意参数化的黑箱，而是由熵正则control-as-inference 推导出的Perron eigenfunction 决定：

$$u_\theta(x, a) \longrightarrow \pi_\theta(a | x). \quad (83)$$

这使得大偏差、Doob transform、free energy density 与RL policy learning 可以放在同一套数学结构中。

8 建议的研究路线

8.1 第一步：小体系精确验证

选一个小 L 的最近邻reward 多agent 受控链。显式构造 K_β ，直接对角化得到

$$\rho_\beta, \quad u_\beta, \quad \pi_\beta^*. \quad (84)$$

这一步用于确认公式、reward 定义和policy 重构没有歧义。

8.2 第二步：MPO-MPS model-based 求解

把同一个 K_β 写成MPO，用MPS 近似 $u_\beta(x, a)$ 。比较：

$$\rho_{\text{MPS}} \quad \text{vs.} \quad \rho_{\text{exact}}, \quad (85)$$

以及由MPS policy 生成的轨迹observable。

8.3 第三步：MPS u - θ learning

不再显式构造 K_β ，只从prior dynamics 采样transition。用(71) 或(74) 学习 u_θ 与 ρ 。再与model-based MPS 结果比较。

8.4 第四步：有限尺寸标度与热力学极限

增加 L ，研究

$$\frac{1}{L} \log \rho_{\beta, L} \quad (86)$$

和局域observable 的收敛。若有限尺寸结果稳定，再转向iMPS/iMPO。

9 小体系三步验证结果

9.1 验证设置

作为最小可复现实验，取

$$L = 6, \quad N = 3, \quad (87)$$

即固定粒子数sector 中共有

$$|\mathcal{S}_{6,3}| = \binom{6}{3} = 20 \quad (88)$$

个构型。action 是所有bond 与方向：

$$|\mathcal{A}| = 2(L - 1) = 10. \quad (89)$$

因此state-action 空间维数为

$$|\mathcal{S}_{6,3}| |\mathcal{A}| = 200. \quad (90)$$

参数取

$$\beta = 1, \quad V = 0.7, \quad \lambda = 0.25, \quad c_+ = c_- = 0.03, \quad q_+ = q_- = 0.9. \quad (91)$$

MPS 使用action-marker 编码，局域维数 $d_{\text{loc}} = 6$ ，bond dimension 取 $\chi = 16$ 。

9.2 第一步：精确state-action Perron 解

显式构造 200×200 的tilted matrix K_β ，并求解

$$K_\beta^\top u_\beta = \rho_{\beta, L} u_\beta. \quad (92)$$

这里使用 $K_\beta^\top$ 是因为矩阵元按

$$K_\beta(n', a' | n, a) \quad (93)$$

存储为“row = next, column = current”。Arriojas 公式中的 u 满足

$$\sum_{n', a'} K_\beta(n', a' | n, a) u(n', a') = \rho u(n, a), \quad (94)$$

所以在普通矩阵乘法中对应 $K_\beta^\top$ 的右本征向量。

数值结果为

$$\rho_{\beta, L} = 0.7752221495, \quad \frac{\|K_\beta^\top u - \rho u\|}{\|u\|} = 2.47 \times 10^{-15}. \quad (95)$$

由

$$\pi^*(a | n) = \frac{\pi_0(a | n) u(n, a)}{\sum_b \pi_0(b | n) u(n, b)} \quad (96)$$

得到的最优policy 是非均匀的。例如对构型111000，最优动作是向右移动第三个bond 上的粒子，其概率约为0.722。

9.3 第二步：MPO-MPS model-based 求解

第二步不再把 $u(n, a)$ 当作表，而是取

$$u_\theta(n, a) = \exp f_\theta(n, a), \quad (97)$$

其中 f_θ 是action-marker MPS。利用已知的局域transition gate、最近邻reward diagonal MPO 和next-action prior，代码中实现了一个有限状态自动机MPO。它逐站点扫描 $y_j = (n_j, m_j)$ 与 $y'_j = (n'_j, m'_j)$ ，MPO virtual index 记录四类信息：是否已经看到输入action marker、是否正处在active bond 的第二个site、是否已经生成输出action marker，以及最近邻reward 所需的前一个 n'_j 。在合法fixed- N state-action sector 上，这个MPO contraction 得到的矩阵元与直接构造的dense K_β 逐元素一致：

$$\max_{z, z'} |K_\beta^{\text{MPO}}(z' | z) - K_\beta^{\text{dense}}(z' | z)| = 1.39 \times 10^{-17}, \quad (98)$$

相对Frobenius 误差为

$$\frac{\|K_\beta^{\text{MPO}} - K_\beta^{\text{dense}}\|_F}{\|K_\beta^{\text{dense}}\|_F} = 7.45 \times 10^{-17}. \quad (99)$$

随后用这个显式MPO 生成的operator 对每个state-action 对计算

$$(K_\beta u_\theta)(n, a) = \sum_{n', a'} K_\beta(n', a' | n, a) u_\theta(n', a'). \quad (100)$$

训练目标取log-residual:

$$\mathcal{L}_{\text{model}} = \frac{1}{|\mathcal{S}||\mathcal{A}|} \sum_{n, a} [\log(K_\beta u_\theta)(n, a) - \log \rho_\theta - \log u_\theta(n, a)]^2. \quad (101)$$

在 $\chi = 16$ 下得到

$$\rho_\theta = 0.7749303292, \quad \frac{|\rho_\theta - \rho_{\text{exact}}|}{\rho_{\text{exact}}} = 3.76 \times 10^{-4}. \quad (102)$$

本征残差为

$$\frac{\|K_\beta u_\theta - \rho_\theta u_\theta\|}{\|u_\theta\|} = 3.64 \times 10^{-4}, \quad (103)$$

并且MPS 学到的 u_θ 与精确 u 的归一化内积为

$$\frac{\langle u_\theta, u_{\text{exact}} \rangle}{\|u_\theta\| \|u_{\text{exact}}\|} = 0.9999992. \quad (104)$$

这说明在这个小体系上，state-action Perron eigenfunction 确实可以被低bond dimension MPS 高精度表示。

9.4 第三步：MPS u - θ learning

第三步不显式构造 K_β ，只从prior policy 与环境transition 中采样

$$(n_t, a_t, r_t, n_{t+1}, a_{t+1}). \quad (105)$$

使用半梯度TD 形式:

$$\delta_t = e^{\beta r_t} u_\theta(n_{t+1}, a_{t+1}) - \rho_\theta u_\theta(n_t, a_t), \quad (106)$$

但对target 部分停止梯度，以避免把单样本transition noise 当作确定性Bellman 残差压掉。同时用batch ratio

$$\rho_{\text{target}} = \left\langle e^{\beta r_t} \frac{u_\theta(n_{t+1}, a_{t+1})}{u_\theta(n_t, a_t)} \right\rangle_{\text{batch}} \quad (107)$$

辅助更新 ρ_θ 。

在同样的 $\chi = 16$ 下，采样学习得到

$$\rho_\theta = 0.7539960617, \quad \frac{|\rho_\theta - \rho_{\text{exact}}|}{\rho_{\text{exact}}} = 2.74 \times 10^{-2}. \quad (108)$$

本征残差为

$$\frac{\|K_\beta u_\theta - \rho_\theta u_\theta\|}{\|u_\theta\|} = 8.33 \times 10^{-2}, \quad (109)$$

而 u_θ 与精确 u 的归一化内积为

$$0.9909. \quad (110)$$

因此，model-free 的MPS u - θ learning 在这个小体系上已经学到正确的eigenfunction 方向，但 ρ 和残差精度明显低于model-based MPO-MPS 求解。这是合理的：第三步只使用采样，并且没有显式做Bellman expectation。

10 总结

这条路线的关键不是把maze 做大，而是把问题换成受控many-body 随机过程。固定格点随机模型只给出大偏差谱问题；加入真实action 后，才得到真正的MDP。张量网络表示的核心对象也不是普通表格 Q ，而是state-action Perron eigenfunction $u(n, a)$ 。model-based 情况下它由MPO-MPS 本征值问题求得；model-free 情况下它由MPS 版本的 u - θ learning 从样本中学得。